

순환신경망을 이용한 한글 필기체 인식

(Hangul Handwriting Recognition using Recurrent Neural Networks)

김 병 희 [†] 장 병 탁 ^{††}
(Byoung-Hee Kim) (Byoung-Tak Zhang)

요 약 온라인 방식의 한글 필기체 인식 문제를 분석하고 순환신경망 기반의 해법을 모색한다. 한글 낱글자 인식 문제를 순서데이터 레이블링의 관점에서 서열 분류, 구간 분류, 시간별 분류의 세 단계로 구분하여 각각에 대한 해법을 살펴보고, 한글의 구성 원리를 고려한 해결 방안을 정리한다. 한글 2350글자에 대한 온라인 필기체 데이터에 GRU(gated recurrent unit)의 다층 구조를 가지는 서열 분류모델을 적용한 결과, 낱글자 인식 정확도는 86.2%, 초·중·종성 구성에 따른 6가지 유형 분류 정확도는 98.2%로 측정되었다. 유형 분류 모델로 확의 진행에 따른 유형 변화 역시 높은 정확도로 인식하는 결과를 통해, 순환신경망을 이용하여 순서 데이터에서 한글의 구조와 같은 고차원적 지식을 학습할 수 있음을 확인하였다.

키워드: 순환신경망, 한글필기체 인식, 딥러닝 응용, 한글 구성 원리를 고려한 인식, 온라인 필기체 인식

Abstract We analyze the online Hangul handwriting recognition problem (HHR) and present solutions based on recurrent neural networks. The solutions are organized according to the three kinds of sequence labeling problem - sequence classifications, segment classification, and temporal classification, with additional consideration of the structural constitution of Hangul characters. We present a stacked gated recurrent unit (GRU) based model as the natural HHR solution in the sequence classification level. The proposed model shows 86.2% accuracy for recognizing 2350 Hangul characters and 98.2% accuracy for recognizing the six types of Hangul characters. We show that the type recognizing model successfully follows the type change as strokes are sequentially written. These results show the potential for RNN models to learn high-level structural information from sequential data.

Keywords: recurrent neural networks, Hangul handwriting recognition, deep learning application, online handwriting recognition

· 이 논문은 2016년도 정부(미래창조과학부)의 재원으로 정보통신기술진흥센터(R0126-16-1072-SW스타랩)와 한국산업기술평가관리원(10044009-HRI.MESSI, 10060086-RISF)의 지원을 받아 수행된 연구이며, 삼성전자의 지원을 일부 받았음
· 이 논문은 2016 한국컴퓨터종합학술대회에서 '순환신경망을 이용한 한글 필기체 인식'의 제목으로 발표된 논문을 확장한 것임

[†] 학생회원 : 서울대학교 컴퓨터공학부 박사과정 연구원
(Seoul Nat'l Univ.)
bhkim@bi.snu.ac.kr
(Corresponding author임)

^{††} 종신회원 : 서울대학교 컴퓨터공학부 교수
btzhang@bi.snu.ac.kr

논문접수 : 2016년 10월 10일
(Received 10 October 2016)
논문수정 : 2017년 2월 1일
(Revised 1 February 2017)
심사완료 : 2017년 2월 14일
(Accepted 14 February 2017)

Copyright©2017 한국정보과학회 : 개인 목적이나 교육 목적인 경우, 이 저작물의 전체 또는 일부에 대한 복사본 혹은 디지털 사본의 제작을 허가합니다. 이 때, 사본은 상업적 수단으로 사용할 수 없으며 첫 페이지에 본 문구와 출처를 반드시 명시해야 합니다. 이 외의 목적으로 복제, 배포, 출판, 전송 등 모든 유형의 사용행위를 하는 경우에 대하여는 사전에 허가를 얻고 비용을 지불해야 합니다.
정보과학회 컴퓨팅의 실제 논문지 제23권 제5호(2017. 5)

1. 서론

필기체 인식은 컴퓨터가 다양한 형태의 필기 입력을 인식하는 문제이며, 인공지능 분야의 대표적인 응용문제 중 하나로 여전히 활발히 연구되는 주제이다. 이미 쓰인 필기 정보를 이미지로 입력받는 오프라인 방식과, 펜촉의 움직임 정보(좌표, 필기면 접촉 여부)를 입력으로 하는 온라인 방식으로 크게 구분된다.

필기체 글자 인식의 경우, 기존에는 연구자별로 다양한 언어와 문제에 따라 경험적으로 선정한 특성값(feature)을 추출하여 분류 알고리즘으로 인식하는 것이 일반적이었으나, 최근에는 문제의 종류에 무관하게 딥러닝이라는 공통의 프레임 하에서 해법을 구성하고 있다. 컨벌루션 신경망(CNN)과 순환신경망(RNN)이 숫자 인식[1], 영어 인식[2], 중국어 인식[3], 아라비아어 인식[4] 등에서 낱글자와 문장 인식 모두 기존 방법 대비 큰 성능 향상을 보인 바 있으며, 90% 중후반대의 높은 성능을 보이기도 한다. 이러한 동향과는 달리, 한글 필기체 인식 문제의 경우 학계에서의 연구는 다른 언어에 비해 상대적으로 정제된 것으로 보인다. 은닉마코프모델(HMM) 또는 동적 베이즈안망(DBN) 기반의 온라인 인식 기법이 주로 사용되는 와중에[5,6] 최근 컨벌루션 신경망을 이용한 오프라인 인식 결과가 발표되고 있다[7,8].

본 논문에서는 한글 필기체 인식 문제에서 온라인 방식의 해법 체계를 정리하고, 한글 낱글자 인식 문제에 대해 순환신경망 기반의 딥러닝 기법의 유용성을 실험을 통해 확인한 결과를 보고한다.

2. 한글필기체 인식 문제

이 절에서는 온라인 필기체 인식 문제에 대한 일반적인 분석과 한글 필기체 인식의 특성을 정리한다. 온라인 필기체 인식 문제의 핵심 과정은 순서데이터 레이블링이며, 다음과 같이 세 종류의 문제로 구분된다[9].

- 서열 분류(sequence classification): 하나의 서열 데이터별로 하나의 레이블이 부여되는 문제. 한 순서데이터에 대한 레이블의 길이가 1로 제한된다.
 - 구간 분류(segment classification): 순서데이터 내에서 구간별로 레이블이 주어짐. 전후 문맥(context)이 중요한 단계이며, 구간과 해당 레이블이 맞춤(align)이 되어 제공되는 것을 전제로 한다.
 - 시간별 분류(temporal classification): 레이블도 서열 형태로 주어지며, 레이블 서열의 길이가 입력 데이터 서열의 길이 이하라는 조건 외에는 레이블 서열에 대한 조건이 없는 설정이다. 레이블이 부여되는 구간의 경계가 사전에 알려져 있지 않다.
- 온라인 방식의 한글 낱글자 인식 문제에서, 낱글자 내

의 전체 획(strokes) 정보를 입력으로 하고, 글자 또는 글자의 종류 중 하나를 출력으로 하는 경우 첫 번째 설정인 서열 분류 문제에 해당된다. 초성, 중성, 종성별로 각 획이 구분되고 해당 자음 또는 모음이 명시적으로 부여된 데이터가 존재하는 경우 두 번째 설정에 해당하는 구간 분류 문제이다. [6]에서 이와 같은 사례를 다룬 바 있으나, 구간을 명확히 구분하는 작업에 사람이 개입을 해야 하기 때문에 학습 데이터를 구성하고 필기체 인식기를 학습하려면 비용이 많이 든다. 구간 정보가 사전에 알려지지 않더라도 순서대로 초성, 중성, 종성에 해당하는 자음 또는 모음을 레이블로 사용하는 경우 세 번째 시간별 분류 설정의 해법을 적용할 수 있다.

3. 한글필기체 인식 방법

이 절에서는 한글필기체의 온라인 인식에 적용 가능한 알고리즘을 정리한다. 딥러닝을 통해 표상 학습(representation learning)이 가능하고 종단(end-to-end) 방식의 해법을 추구하는 점을 고려하여 특성값(feature) 추출에 대한 논의는 제외한다.

순서가 있는 데이터에서 레이블을 예측하는 문제에는 전통적으로 HMM이 널리 사용되었으며, CRF(conditional random field)도 좋은 선택지 중 하나이다. HMM 모델에서는 은닉 상태가 주어진 경우 시간에 따른 입력값은 무관하다는 가정을 하므로, 서열상의 거리가 먼 입력 간 관계가 원활하게 반영되지 않는 한계가 있다. 이에 대한 대안으로 순환신경망(RNN) 계열의 알고리즘이 연구되었다[10].

고전적인 RNN[11,12]은 싸이클이 있는 망 구조를 허용하며 역전파 과정에서 미분값의 소멸로 인해 안정적인 학습이 어려운 문제가 있어 응용에 제한이 있다. 이를 해결한¹⁾ 대표적 기법인 LSTM(Long Short-Term Memory)[9,13]이 최근 딥러닝 모델의 핵심 도구 중 하나로 각광을 받고 있다. LSTM은 여러 게이트를 이용한 정보의 선택적 전달을 통해 장기간 연관성을 성공적으로 반영한다. 서열의 순방향뿐만 아니라 역순 정보까지 고려하는 양방향(bi-directional) 순환신경망 모델은 음성인식, 영어 필기체 문장 인식 등의 문제에서 공통적으로 적용하는 해법이다. 특히, ‘시간별 분류’ 문제의 경우 CTC(connectionist temporal classification) 출력층의 도입은 필수적인 선택지가 되고 있다[14,15].

한글 낱글자에 대한 온라인 방식 인식에 대한 해법으로, ‘서열 분류’ 단계의 설정에는 LSTM 및 구조를 간소화한 GRU(Gated Recurrent Unit)[16]를 바로 적용

1) 미분값의 폭증 문제도 존재하며, 이 경우 미분값의 상한선을 고정(clipping)하는 방식으로 해결한다.




그림 1 대표적인 두 순환신경망 모델의 hidden unit 구조 [17]. LSTM은 입력(i), 망각(f), 출력(o) 세 개의 ‘게이트’를 두고, GRU는 리셋(r), 업데이트(z) 두 개의 게이트로 메모리와 정보 흐름을 조절한다.

Fig. 1 Structure diagrams of two representative recurrent neural network models [17]. The LSTM contains three gates (input, forget, and output). The GRU controls memory and information flow using reset (r) and update (z) gates

할 수 있다(그림 1). 그러나, 초성·중성·종성의 순서가 있는 한글의 구조적 특성을 반영하여, 자음, 모음, 받침 용 자음의 순서를 부분적 레이블로 활용한다면, ‘시간별 분류’ 설정의 해법을 적용할 수 있으며, CTC 기법을 활용할 수 있다. 낱글자의 초·중·종성 구성은 고정된 정보이므로 부분 레이블로 반영하는 데 들어가는 비용은 서열 분류 단계와 거의 차이가 나지 않는다.

4. 실험 및 결과

이 절에서는 한글 낱글자 인식 문제를 ‘서열 분류’ 단계(2절 참조)에서 순환신경망 모델을 구현하고 성능 평가를 수행한 결과를 정리한다.

실험에 사용한 한글 필기체 데이터는 미공개 대규모 데이터베이스이며 KS완성형 2350글자 각각에 대해 500 개씩의 샘플로 구성된 데이터(A)와, 다른 환경에서 수집한 글자당 50개 샘플로 구성된 데이터(B)로 구성되어 있다. 각 샘플은 온라인 방식의 필기체 정보, 즉 펜의 위치(x, y)와 상태 정보(up/down)를 담고 있다. 글자 크기에 대해, 가로축과 세로축 중 긴 축의 길이를 1.0으로 조정하는 정규화를 적용하였다. 데이터 A 중 80%를 학습 데이터로 사용하고, 나머지 20%와 데이터 B를 테스트 데이터로 적용하였다.

순환신경망 모델로는 LSTM보다 간단하며 성능 차이가 유의미하지 않거나 더 나은[17,18] GRU를 적용하였다. 다양한 길이를 가지는 데이터로 학습하기 위해, 입력 서열을 마스킹 레이어에 통과시켜 지정 길이(600 points)보다 긴 부분은 삭제하고, 지정 길이보다 짧은 데이터의 경우 입력 데이터 이후는 0으로 채워 학습과 평가에 반영되지 않도록 하였다. 마지막 GRU층의 출력값을 dropout

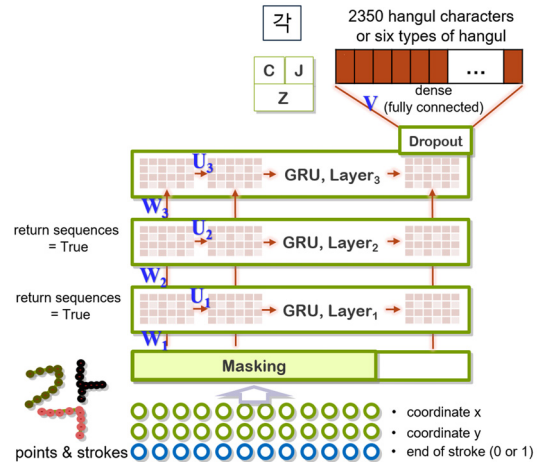


그림 2 온라인 방식으로 한글 낱글자와 유형을 인식하기 위한 순환신경망 구조 사례. 펜 접촉점의 좌표와 획의 순차적 입력 패턴을 다층 순환신경망을 통해 고정 길이의 메모리 패턴(이 그림에서는 GRU 3번째 층의 셀 배열)으로 요약하고 분류하는 학습을 수행한다.

Fig. 2 An example RNN model for online Hangul character recognition. This multi-layer model is trained with sequences of point coordinates and strokes to summarize them into a fixed length memory pattern and recognize labels based on it




그림 3 한글의 초성(C), 중성(J), 종성(Z) 구성에 따른 여섯 가지 유형 구분[6]

Fig. 3 Six types of Hangul characters according to the constitution of the starting consonant (C), middle vowel (J), and the final consonant(s) (Z)

(확률 0.5)을 적용한 완전연결망에 연결하고 softmax를 이용한 낱글자별 확률을 얻는다. GRU의 은닉노드의 수와 층 개수의 다양한 조합에 대해 파라미터의 수, 학습 속도와 인식 성능을 점검하였다. 이와 같은 구조의 신경망의 한 예를 그림 2와 같이 도식화하였다.

실험은 2350가지 한글 낱글자 인식 문제와, 한글의 초성·중성·종성 구성에 따른 6가지 유형(그림 3) 분류 문제로 구성하였다. 표 1에 낱글자 인식, 유형 인식 실험의 설정과 성능에 대한 정보를 정리하였다. 표 2, 표 3과 그림 4에 모델 간 성능 비교 결과를 요약하였다.

표 2에서 다음과 같은 비교분석이 가능하다. 기존 온라인 필기체 인식기법 중 Lipi Toolkit[19]의 특성값과

표 1 순환신경망을 이용한 한글 필기체 인식 기법의 환경 설정과 인식 결과

Table 1 Hangul handwriting recognition results (Environments: [S/W] Ubuntu 14.04, Keras 1.0.6, backend=Theano 0.8.2, [H/W] Intel i5-6600, Titan X D5 (VRAM 12G) * 1 node, RAM DDR-4 64G)

Problems	Model Configuration <# parameters>	Configuration for Learning	Highest Accuracies		Elapsed Time
			Test Set A	Test Set B	
Character Recognition	Masking - GRU[64] * 3 Layers - Dropout(0.5) - Dense[2350] <215,797>	optimizer=adam, objective function = softmax cross-entropy, batch size = 128	97.2%	86.2%	~110 hr
Six type Recognition	Masking - GRU[64] * 3 Layers - Dropout(0.5) - Dense[6] <62,982>		99.7%	98.2%	~2.5 hr

표 2 한글 낱글자 인식성능 비교

Table 2 Comparison of recognition accuracies for 2350 Hangul characters (%). The recognition using features learned by RNN (last three rows) are conducted using the default setting of each classifier in Weka 3.8.0

Model	Classifier	Test Set A	Test Set B
LIPI ToolKit	1-Nearest Neighbor	73.0	61.0
GRU[64] × 1 layer	Softmax Regression +	94.7	80.9
GRU[64] × 2 layer		97.1	85.8
GRU[64] × 3 layer	Dropout	97.2	86.2
Features from RNN (GRU[64] × 3 layer)	Naive Bayes	96.1	80.4
	Decision Tree	92.9	74.7
	1-Nearest Neighbor	96.9	85.8

표 3 한글 글자의 여섯 가지 유형 인식 정확도(%)

Table 3 Recognition accuracies of six character types

Model	# parameters	Fine-tuning Output Layer		Learning All Layers	
		A	B	A	B
GRU[32] × 1 layer	3,654	-	-	98.8	96.6
GRU[64] × 1 layer	13,446	92.3	90.4	99.4	98.1
GRU[64] × 2 layer	38,214	90.7	89.0	99.5	98.1
GRU[64] × 3 layer	62,982	87.5	86.8	99.7	98.2

1-최근접이웃 분류기를 적용한 성능을 기준으로, 1) 순환신경망 인식기의 성능이 월등히 높으며, 2) 순환신경망으로 학습한 필기체 정보 요약 메모리 패턴은 기본적인 분류 알고리즘으로도 인식 성능이 높은 우수한 특성값으로 사용 가능하다. 3) 순환신경망의 출력 정보에 softmax와 드롭아웃만을 적용한 분류기의 성능이, 특성이




그림 4 모델의 용량에 따른 학습 성능 비교

Fig. 4 Performances vs. model capacities (x axis: epoch)

다른 분류 알고리즘과 비교해 성능 면에서 뒤처지지 않는다.

일반적으로 순환신경망 분류모델의 성능은 은닉노드와 층의 수에 영향을 받을 것으로 예상되나, 표 2, 표 3과 그림 4를 통해 다음과 같은 분석이 가능하다. 층의 수를 늘릴 때의 성능 향상 효과는 확인되지 않았으며, 모델의 용량(매개변수의 수)이 어느 이상이 되는 경우 최고 성능의 차이는 유사하다. 모델 용량이 커질수록 적은 반복학습으로도 성능이 향상되지만, 너무 큰 경우 학습 과정 중간에 불규칙한 성능 출렁임이 관찰되었다. 참고로, 다층 구조의 학습 결과 모델에서, 최종 층 이전의 메모리 패턴을 특성값으로 적용한 분류 성능은 상대적으로 낮았다(정확도 25% 미만).

순환신경망 기반 인식기로 한글 구조에 대한 보다 고차원적인 패턴 인식이 가능한지를 확인하기 위해 한글 6유형 인식 모델을 학습하였다. 전이학습 관점에서, 낱글자 인식을 학습한 순환신경망에서 출력층을 한글 6유형 층으로 대체하고 출력층의 가중치만을 학습하는 미세 조율 결과, 테스트 데이터 A, B 기준 인식 정확도는 87~92%이고, 과다학습 현상이 나타났다. 전체 순환신경망을 학습한 경우에는 100%에 가까운 인식률을 보였다(표 3).

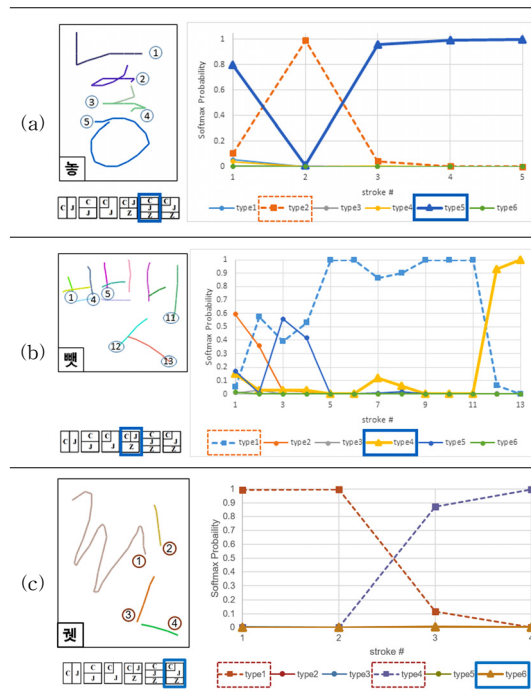


그림 5 한글 유형에 대한 획 단위의 순차적 인식 과정 사례 분석. 유형을 정확히 인식한 경우(a, b), 획이 진행됨에 따라 해당 유형의 확률이 순차적으로 최대로 관측된다. 유형을 인식하지 못한 경우 중 (c)의 사례에서는 초성과 중성을 이어 쓰는 과정에서 복모음 '네'가 제대로 인식되지 않았다.

Fig. 5 Analyses of Hangul sequential recognition types for every end-of-stroke points. In correctly recognized cases (a, b), as strokes are added, corresponding types eventually get high probabilities. In an incorrect case (c), the initial consonant and a part of the vowel are drawn in one stroke, causing misconception of the complex vowel '네'.

학습한 순환신경망으로 임의의 길이의 필기체를 인식할 수 있다. 그림 5에 테스트 데이터에서 획 단위의 한글 유형 인식 결과에 대한 상세 분석 사례를 정리하였다. 정자에 가깝게 획을 순서대로 쓰는 경우 유형이 정확히 인식되지만(a, b), 초성과 중성의 획을 합쳐서 쓰는 경우 잘못 인식되는 사례(c)를 볼 수 있다. 획의 진행에 따른 유형의 변화 또한 정확히 인식함을 확인할 수 있다.

마지막으로, 유형 인식률이 높은 점을 활용하여, 유형 인식 후 유형 내에서 해당 낱글자를 인식하는 계층적 인식도 가능하다. 표 1에서 보고한 두 모델을 결합하여, 빔 탐색($n=2$)으로 두 계층의 예측 확률의 곱이 가장 높은 후보를 선택하는 방식으로 낱글자 인식을 진행한 결

과, 표 1의 낱글자 인식기의 성능이 테스트 데이터 A는 97.3%, B는 86.5%로 약간 향상되었다.

5. 결론

본 논문에서는 한글 온라인 필기체 인식 문제에 대한 분석과 순환신경망 기반의 해법을 정리하고, 대규모 데이터에 대한 실험을 통해 2350글자에 대한 낱글자 인식 정확도 86.2%, 6가지 한글 유형 인식 정확도 98.2%의 성능을 확인하였다. 순환신경망 모델이 온라인 한글 필기체 데이터를 학습하여 낱글자뿐만 아니라 한글의 초성, 중성, 종성 구조와 조합도 인식할 수 있음을 살펴보았다.

후속 연구로는 시간별 분류 단계의 해법으로 양방향(bi-directional) 순환신경망을 적용하고[14][20], 초·중·종성을 반영한 CTC 층을 추가로 구현하는 방향을 고려하고 있다. 또한 영어 필기체에서 이미 성공적으로 적용된 바와 같이[14], 순환신경망 모델을 이용하여 문장 단위의 한글 온라인 필기체 인식을 시도하는 것이 유의미한 후속 연구가 될 것이다.

References

- [1] D. Ciresan, U. Meier, J. Schmidhuber, Multi-column Deep Neural Networks for Image Classification, *Proc. CVPR*, pp. 3642-3649, 2012.
- [2] M. Liwicki, A. Graves, S. Fernández, H. Bunke, J. Schmidhuber, A Novel Approach to On-Line Handwriting Recognition Based on Bidirectional Long Short-Term Memory Networks, *Proc. ICDAR*, pp. 367-371, 2007.
- [3] F. Yin, Q.-F. Wang, X.-Y. Zhang, and C.-L. Liu, ICDAR 2013 Chinese Handwriting Recognition Competition, *Proc. ICDAR*, pp. 1464-1470, 2013.
- [4] A. Graves and J. J. Schmidhuber, Offline Handwriting Recognition with Multidimensional Recurrent Neural Networks, *Proc. NIPS*, pp. 545-552, 2008.
- [5] B.-K. Sin and J. Kim, "Ligature Modeling for Online Cursive Script Recognition," *IEEE Trans. Pattern Anal. Mach. Intell.*, Vol. 19, No. 6, pp. 623-633, 1997.
- [6] S. Cho and J. Kim, Bayesian Network Modeling of Hangul Characters for On-line Handwriting Recognition, *Proc. ICDAR*, pp. 207-211, 2003.
- [7] I. J. Kim and X. H. Xie, "Handwritten Hangul Recognition Using Deep Convolutional Neural Networks," *Int. J. Doc. Anal. Recognit.*, Vol. 18, No. 1, pp. 1-13, 2015.
- [8] I. J. Kim, C. B. Choi, and S. H. Lee, "Improving Discrimination Ability of Convolutional Neural Networks by Hybrid Learning," *Int. J. Doc. Anal. Recognit.*, Vol. 19, No. 1, pp. 1-9, 2016.
- [9] A. Graves, Supervised Sequence Labelling with

- Recurrent Neural Networks, Textbook, Studies in Computational Intelligence, Springer, 2012.
- [10] H. Yoon, D. Jeong, and K. Jung, "Structure of Recurrent Neural Networks and Handwriting Recognition," *Communications of the Korean Institute of Information Scientists and Engineers*, Vol. 33, No. 9, pp. 42-48, 2015. (in Korean)
 - [11] J. L. Elman, "Finding Structure in Time," *Cognitive Science*, Vol. 14, No. 2, pp. 179-211, 1990.
 - [12] M. I. Jordan, Attractor Dynamics and Parallelism in a Connectionist Sequential Machine, *Proc. CogSci*, pp. 531-546, 1986.
 - [13] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Comput.*, Vol. 9, No. 8, pp. 1735-1780, 1997.
 - [14] A. Graves, S. Fernandez, F. Gomez, and J. Schmidhuber, Connectionist Temporal Classification: Labeling Unsegmented Sequence Data with Recurrent Neural Networks, *Proc. ICML*, pp. 369-376, 2006.
 - [15] A. Graves, A. Mohamed, G. Hinton, Speech Recognition with Deep Recurrent Neural Networks, *Proc. ICASSP*, pp. 6645-6649, 2013.
 - [16] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation, *Proc. EMNLP*, pp. 1724-1734, 2014.
 - [17] J. Chung, C. Gulcehre, K.H. Cho, and Y. Bengio, "Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling," arXiv:1412.3555, 2014.
 - [18] R. Jozefowicz, W. Zaremba, and I. Sutskever, An Empirical Exploration of Recurrent Neural Network Architectures, *Proc. ICML*, 37, pp. 2342-2350, 2015.
 - [19] HP Labs India (2013, Jun. 25), Lipi Toolkit for online Handwriting Recognition (HWR) [Online]. Available: <http://lipitk.sourceforge.net/> (downloaded 2017, Jan. 20)
 - [20] M.-C. Lee and S.-B. Cho, "Accelerometer-Based Gesture Recognition Using Hierarchical Recurrent Neural Network with Bidirectional Long Short-Term Memory," *Journal of KIISE: Software and Applications*, Vol. 39, No. 12, pp. 1005-1011, 2012. (in Korean)

장 병 탁

정보과학회 컴퓨팅의 실제 논문지
제 23 권 제 2 호 참조



김 병 회

2003년 서울대학교 컴퓨터공학부 학사
2006년 서울대학교 컴퓨터공학부 박사과
정 수료. 2006년 독일 베를린공대 방문연
구원. 2006년~현재 서울대학교 컴퓨터공
학부 연구원. 관심분야는 머신러닝, 딥러
닝, 인공지능, 순서 패턴 인식 및 생성